

Laporan Analisis Klaster

Dataset Absenteeism at Work

Reka Pandu Anggara (3338240021)

2026-06-04

Table of Contents

1	Deskripsi dan Karakteristik Dataset.....	2
2	Data Preprocessing.....	2
2.1	Load Library	2
2.2	Impor Data dan Pengecekan Missing Value	3
2.3	Pemilihan Variabel dan Scaling.....	4
3	Exploratory Data Analysis.....	5
3.1	Statistik Deskriptif	5
3.2	Visualisasi Distribusi	7
3.3	Matriks Korelasi.....	8
4	Optimasi Parameter.....	9
4.1	Penentuan Jumlah Cluster Optimum (k).....	9
4.2	Penentuan Linkage Terbaik untuk Hierarchical Clustering (AGNES).....	12
4.3	Penentuan Parameter DBSCAN (eps dan minPts).....	13
5	Eksekusi Pemodelan	14
5.1	K-Means.....	15
5.2	Hierarchical Clustering (AGNES)	18
5.3	DBSCAN	21
6	Validasi	25
6.1	Validasi Kriteria Internal (Silhouette Width)	25
6.2	Validasi Konsensus (Cross-Tabulation)	28
7	Kesimpulan	30

1 Deskripsi dan Karakteristik Dataset

Analisis ini menggunakan dataset Absenteeism at Work yang mencakup data ketidakhadiran karyawan di tempat kerja beserta berbagai atribut demografis, kesehatan, dan perilaku. Dataset ini memuat 740 baris observasi dan 21 kolom variabel.

Fokus analisis klasterisasi dipusatkan pada 6 variabel numerik kontinu yang merepresentasikan karakteristik personal dan pekerjaan karyawan, yaitu:

- Transportation expense: Biaya transportasi harian karyawan (dalam satuan mata uang).
- Distance from Residence to Work: Jarak tempat tinggal ke tempat kerja (dalam km).
- Age: Usia karyawan (dalam tahun).
- Work load Average/day: Rata-rata beban kerja per hari.
- Body mass index: Indeks massa tubuh karyawan.
- Absenteeism time in hours: Total jam ketidakhadiran karyawan.

Variabel lainnya seperti ID, Reason for absence, Month of absence, Day of the week, dan variabel kategoris biner (Disciplinary failure, Social drinker, Social smoker) tidak dilibatkan dalam proses pemodelan klasterisasi karena bersifat kategoris atau merupakan pengenalan observasi. Karakteristik utama dari data karyawan ini adalah adanya distribusi yang tidak simetris, terutama pada variabel Absenteeism time in hours yang memiliki nilai ekstrem (outliers) cukup masif.

2 Data Preprocessing

2.1 Load Library

Langkah awal adalah mengaktifkan seluruh pustaka R yang diperlukan untuk manipulasi data, ringkasan statistika deskriptif, penentuan parameter, pengekseskuan 3 algoritma klasterisasi (K-Means, Hierarchical/AGNES, dan DBSCAN), serta kebutuhan visualisasi grafik.

```
library(readxl)
library(tidyverse)
library(cluster)
library(factoextra)
```

```
library(dbscan)
library(knitr)
library(kableExtra)
library(corrplot)
library(gridExtra)
```

2.2 Impor Data dan Pengecekan Missing Value

Data diimpor dari berkas Excel lokal. Sebelum melakukan analisis lebih mendalam, dimensi matriks diperiksa untuk memastikan keutuhan data (740 baris, 21 kolom) serta dilakukan pemindaian nilai kosong (*missing values*) untuk menjamin kelancaran komputasi algoritma.

```
absen <- read_excel("D:/STATISTIKA UNTIRTA/Statistical Mechine
Learning/Absenteeism_at_work.xlsx")
```

```
cat("Dimensi Dataset:\n")
```

```
## Dimensi Dataset:
```

```
print(dim(absen))
```

```
## [1] 740 21
```

```
cat("\nPengecekan Missing Values pada Tiap Kolom:\n")
```

```
##
```

```
## Pengecekan Missing Values pada Tiap Kolom:
```

```
print(colSums(is.na(absen)))
```

```
##                               ID                Reason for absence
##                               0                               0
##                Month of absence                Day of the week
##                               0                               0
##                Seasons                Transportation expense
##                               0                               0
## Distance from Residence to Work                Service time
##                               0                               0
##                Age                Work load Average/day
##                               0                               0
##                Hit target                Disciplinary failure
##                               0                               0
##                Education                Son
##                               0                               0
##                Social drinker                Social smoker
##                               0                               0
##                Pet                Weight
##                               0                               0
##                Height                Body mass index
```

```
##                                0                                0
##      Absenteeism time in hours
##                                0
```

Tidak ditemukan adanya data yang kosong atau hilang (*missing values*) pada setiap kolom di dalam dataset Absenteeism at Work. Seluruh 740 baris data terisi secara utuh, sehingga dataset ini sudah bersih dan siap untuk langsung digunakan dalam proses transformasi (*scaling*) dan pemodelan klasterisasi tanpa perlu melakukan imputasi data.

2.3 Pemilihan Variabel dan Scaling

Dilakukan proses *slicing* untuk mengisolasi 6 variabel numerik yang akan digunakan dalam klasterisasi. Karena rentang nilai antar-variabel memiliki perbedaan skala yang sangat jauh (misalnya Work load Average/day berkisar ratusan ribu sementara Age hanya puluhan), transformasi standarisasi menggunakan **Z-score** mutlak diterapkan agar seluruh variabel memiliki bobot rentang yang seragam (Mean = 0, SD = 1) sebelum dihitung jarak geometrisnya.

```
# Pemilihan variabel untuk klasterisasi
cluster_vars <- c("Transportation expense",
                  "Distance from Residence to Work",
                  "Age",
                  "Work load Average/day",
                  "Body mass index",
                  "Absenteeism time in hours")

data_cluster <- absen %>% select(all_of(cluster_vars))

# Rename kolom agar lebih ringkas
colnames(data_cluster) <- c("Transport_Exp", "Distance", "Age",
                           "Workload", "BMI", "Absenteeism_Hours")

# Standarisasi Z-score
data_scaled <- data_cluster %>% scale() %>% as_tibble()

# Matriks jarak Euclidean
jarak_matriks <- dist(data_scaled, method = "euclidean")

cat("Dimensi data setelah seleksi variabel:", dim(data_cluster), "\n")
## Dimensi data setelah seleksi variabel: 740 6

cat("\nRingkasan data setelah scaling:\n")
```

```
##
## Ringkasan data setelah scaling:

print(summary(data_scaled))

##   Transport_Exp      Distance      Age      Workload
##   Min.      :-1.54334   Min.      :-1.6601   Min.      :-1.45861   Min.      :-1.6789
##   1st Qu.: -0.63224   1st Qu.: -0.9187   1st Qu.: -0.84121   1st Qu.: -0.6939
##   Median :  0.05482   Median : -0.2447   Median :  0.08489   Median : -0.1854
##   Mean    :  0.00000   Mean    :  0.00000   Mean    :  0.00000   Mean    :  0.00000
##   3rd Qu.:  0.57758   3rd Qu.:  1.3729   3rd Qu.:  0.54794   3rd Qu.:  0.5819
##   Max.    :  2.48939   Max.    :  1.5077   Max.    :  3.32625   Max.    :  2.7496
##      BMI      Absenteeism_Hours
##   Min.      :-1.7914   Min.      :-0.51941
##   1st Qu.: -0.6247   1st Qu.: -0.36939
##   Median : -0.3913   Median : -0.29438
##   Mean    :  0.00000   Mean    :  0.00000
##   3rd Qu.:  1.0088   3rd Qu.:  0.08069
##   Max.    :  2.6422   Max.    :  8.48216
```

3 Exploratory Data Analysis

Langkah ini bertujuan untuk memahami distribusi sebaran data asli. Melalui tabel deskriptif, nilai rata-rata dan kecondongan (*skewness*) dapat dipantau, sementara grafik boxplot dan histogram digunakan untuk mengidentifikasi keberadaan pencilan (*outlier*) pada setiap variabel.

3.1 Statistik Deskriptif

```
# Fungsi hitung skewness manual
skewness_val <- function(x) {
  n <- length(x)
  m <- mean(x, na.rm = TRUE)
  s <- sd(x, na.rm = TRUE)
  sum((x - m)^3, na.rm = TRUE) / ((n - 1) * s^3)
}

stat_tabel <- data_cluster %>%
  summarise(across(everything(), list(
    Mean      = ~round(mean(.x, na.rm = TRUE), 3),
    Std.Dev   = ~round(sd(.x, na.rm = TRUE), 3),
    Min       = ~round(min(.x, na.rm = TRUE), 3),
    Q1        = ~round(quantile(.x, 0.25, na.rm = TRUE), 3),
    Median    = ~round(median(.x, na.rm = TRUE), 3),
    Q3        = ~round(quantile(.x, 0.75, na.rm = TRUE), 3),
```

```

    Max      = ~round(max(.x, na.rm = TRUE), 3),
    Skewness = ~round(skewness_val(.x), 3)
  ))) %>%
pivot_longer(everything(),
              names_to = c("Variabel", ".value"),
              names_sep = "_(?=[^_]+$)" ) %>%
rename(Std.Dev = `Std.Dev`)

kable(stat_tabel,
      format      = "simple",
      caption     = "Ringkasan Statistik Deskriptif Data Absenteeism at
Work",
      align       = "lrrrrrrrrrr") %>%
kable_styling(
)

```

Ringkasan Statistik Deskriptif Data Absenteeism at Work


Variabel	Mean	Std.Dev	Min	Q1	Median	Q3	Max	Skewness
Transport_Exp	221.330	66.952	118.000	179.000	225.000	260.000	388.000	0.395
Distance	29.631	14.837	5.000	16.000	26.000	50.000	52.000	0.311
Age	36.450	6.479	27.000	31.000	37.000	40.000	58.000	0.696
Workload	271.490	39.058	205.917	244.387	264.249	294.217	378.884	0.959
BMI	26.677	4.285	19.000	24.000	25.000	31.000	38.000	0.304
Absenteeism_Hours	6.924	13.331	0.000	2.000	3.000	8.000	120.000	5.705

Berdasarkan output statistika deskriptif terhadap 740 data karyawan, diperoleh karakteristik data sebagai berikut:

- Timbangnya Skala Variabel: Nilai Workload rata-rata mencapai lebih dari 200.000 satuan, jauh lebih besar dibandingkan variabel lainnya. Hal ini menjadi bukti nyata bahwa *scaling* mutlak diperlukan.
- Variabilitas Tinggi: Variabel Absenteeism_Hours memiliki standar deviasi yang hampir dua kali lipat nilai rata-ratanya, menandakan variasi yang sangat lebar antar-karyawan.
- Distribusi Menjulang Kanan: Nilai *Mean* pada variabel Absenteeism_Hours jauh lebih besar dari Median, didukung nilai Skewness positif yang tinggi. Ini menunjukkan mayoritas karyawan memiliki jam absen yang kecil, namun ada segelintir karyawan dengan jam absen sangat tinggi (*outliers*).

3.2 Visualisasi Distribusi


```
par(mar = c(7, 5, 4, 2) + 0.1)
boxplot(data_cluster,
        main = "Distribusi Variabel Klasterisasi (Data Original)",
        col = "steelblue3",
        las = 2,
        ylab = "Nilai",
        names = c("Transport", "Distance", "Age", "Workload", "BMI", "Absen
Hours"))
```



Distribusi Variabel Klasterisasi (Data Original)

```
var_names <- colnames(data_cluster)

par(mfrow = c(2, 3), mar = c(4, 4, 3, 1))
for (var in var_names) {
  hist(data_cluster[[var]],
       main = var,
       xlab = "Nilai",
       col = "steelblue3",
       border = "white",
       breaks = 30)
}
```



Histogram Distribusi Tiap Variabel

```
par(mfrow = c(1, 1))
```

Berdasarkan visualisasi grafik boxplot dan histogram:

- Grafik *boxplot* menunjukkan adanya pencilan masif terutama pada variabel Absenteeism_Hours (melebihi 100 jam) dan Distance. Keberadaan pencilan ekstrem ini menjadi motivasi untuk menggunakan DBSCAN yang secara inheren mampu mendeteksi dan mengklasifikasikan *noise* (outlier) sebagai titik yang tidak masuk kluster manapun.
- Grafik histogram mengonfirmasi bahwa hampir semua variabel memiliki distribusi menjulur positif (*right-skewed*), paling tajam pada Absenteeism_Hours. Hal ini menjadi bukti visual bahwa transformasi standardisasi (*scaling*) mutlak diperlukan agar variabel dengan skala besar tidak mendominasi perhitungan jarak Euclidean.

3.3 Matriks Korelasi


```
cor_matrix <- cor(data_cluster)
corrplot(cor_matrix,
  method = "color",
  type = "upper",
```



```

tl.cex = 0.8,
addCoef.col = "black",
number.cex = 0.7,
title = "Matriks Korelasi Variabel Klasterisasi",
mar = c(0, 0, 1, 0))

```



Matriks Korelasi Antar Variabel

4 Optimasi Parameter

4.1 Penentuan Jumlah Cluster Optimum (k)

Penentuan parameter jumlah kelompok terbaik diuji secara numerik menggunakan dua pendekatan Kriteria Relatif. *Elbow Method* memantau penurunan nilai Total *Within-Cluster Sum of Squares* (WSS), sedangkan *Silhouette Method* mencari nilai rata-rata indeks tertinggi (titik puncak k) untuk menghasilkan partisi yang paling kokoh.

```
set.seed(123)
```


```

# Elbow Method
plot_elbow <- fviz_nbclust(data_scaled,
                          FUNcluster = kmeans,
                          method      = "wss",
                          k.max       = 10) +
  labs(title = "Penentuan Jumlah Cluster Optimum: Elbow Method",
       x     = "Jumlah Cluster (k)",
       y     = "Total WSS")

# Silhouette Method
plot_silhouette <- fviz_nbclust(data_scaled,
                                FUNcluster = kmeans,
                                method      = "silhouette",
                                k.max       = 10) +
  labs(title = "Penentuan Jumlah Cluster Optimum: Silhouette Method",
       x     = "Jumlah Cluster (k)",
       y     = "Avg Silhouette Width")


print(plot_elbow)

```



Penentuan Jumlah Cluster Optimum

```
print(plot_silhouette)
```



Penentuan Jumlah Cluster Optimum

```
# Tabel Numerik Evaluasi k
nilai_wss <- map_dbl(1:10, ~ kmeans(data_scaled,
                                   centers = .x,
                                   nstart = 25)$tot.withinss)
nilai_sil <- map_dbl(2:10, ~ mean(silhouette(
                                   kmeans(data_scaled,
                                           centers = .x,
                                           nstart = 25)$cluster,
                                           jarak_matriks)[, 3]))

tabel_k <- tibble(
  k          = 1:10,
  Total_WSS  = round(nilai_wss, 2),
  Avg_Silhouette = c(NA, round(nilai_sil, 4))
)

kable(tabel_k,
      format = "simple",
      caption = "Tabel Evaluasi Numerik Penentuan k Optimum",
      align  = "crr") %>%
  kable_styling(
  )
```

Tabel Evaluasi Numerik Penentuan k Optimum

k	Total_WSS	Avg_Silhouette
1	4434.00	NA
2	3522.34	0.2366
3	2994.29	0.2491
4	2529.18	0.2605
5	2160.21	0.2749
6	1909.26	0.2809
7	1701.64	0.3086
8	1562.45	0.3313
9	1454.30	0.3477
10	1343.71	0.3659

Berdasarkan output tabel numerik dan visualisasi grafik:

- Elbow Method menunjukkan penurunan WSS yang sangat tajam dari $k=1$ menuju $k=2$, kemudian mulai melandai membentuk tekukan siku (*elbow*). Hal ini menandakan bahwa penambahan jumlah kelompok setelah $k=2$ atau $k=3$ tidak lagi memberikan penurunan variansi internal yang signifikan.
- Silhouette Method menunjukkan puncak tertinggi pada $k=2$ atau $k=3$, dengan nilai *Average Silhouette Width* yang paling mendekati angka 1. Setelah melewati titik puncak tersebut, nilai rata-rata koefisien mengalami penurunan.

Berdasarkan kombinasi kedua metode tersebut, $k = 3$ dipilih sebagai jumlah kluster optimal karena memberikan keseimbangan terbaik antara kompaktness kluster dan interpretabilitas bisnis yang lebih kaya dibandingkan $k=2$.

4.2 Penentuan Linkage Terbaik untuk Hierarchical Clustering (AGNES)

Pada algoritma *Hierarchical Clustering* (AGNES), penentuan jenis *linkage* sangat memengaruhi bentuk pohon keputusan. Perulangan otomatis diterapkan untuk menghitung *Agglomerative*

Coefficient (AC) dari metode average, single, complete, dan ward. Nilai AC yang paling mendekati angka 1 dipilih sebagai struktur penggabungan hierarki terkuat.

```
metode_linkage <- c("average", "single", "complete", "ward")
nilai_ac      <- map_dbl(metode_linkage,
                        ~ agnes(data_scaled, method = .x)$ac)

tabel_ac <- tibble(
  Metode_Linkage = metode_linkage,
  Nilai_AC       = round(nilai_ac, 4)
) %>% arrange(desc(Nilai_AC))

kable(tabel_ac,
      format = "simple",
      caption = "Perbandingan Nilai Agglomerative Coefficient (AC) per Metode Linkage",
      align = "lr") %>%
  kable_styling(
  )
```

Perbandingan Nilai Agglomerative Coefficient (AC) per Metode Linkage

Metode_Linkage	Nilai_AC
ward	0.9931
complete	0.9764
average	0.9708
single	0.9425

```
linkage_best <- metode_linkage[which.max(nilai_ac)]
cat("Metode Linkage Terbaik:", linkage_best,
    "dengan AC =", round(max(nilai_ac), 4), "\n")

## Metode Linkage Terbaik: ward dengan AC = 0.9931
```


4.3 Penentuan Parameter DBSCAN (eps dan minPts)

Algoritma DBSCAN memerlukan dua parameter utama: eps (radius lingkungan) dan minPts (jumlah minimum titik). Pendekatan yang digunakan adalah k-NN Distance Plot (grafik jarak tetangga ke-k) di mana nilai eps optimal ditentukan pada titik “siku” (*knee*) grafik.

```
# Gunakan minPts = 2 * dimensi data (aturan praktis)
min_pts <- 2 * ncol(data_scaled)

kNNdistplot(data_scaled, k = min_pts)
title(main = paste("k-NN Distance Plot (k =", min_pts, ")"))
```

```
abline(h = 1.5, col = "red", lty = 2, lwd = 2)
legend("topleft",
      legend = "eps = 1.5 (garis referensi)",
      col = "red",
      lty = 2,
      cex = 0.8)
```



k-NN Distance Plot untuk Penentuan eps DBSCAN

Berdasarkan grafik k-NN Distance Plot, titik “siku” (*knee*) terlihat pada kisaran nilai jarak **1.5**, sehingga ditetapkan $\text{eps} = 1.5$ dan $\text{minPts} = 12$ (dua kali jumlah dimensi data) sebagai parameter DBSCAN.

5 Eksekusi Pemodelan

Tiga algoritma clustering yang berbeda dieksekusi dengan mengunci parameter jumlah pembagian kelompok pada tingkat kompleksitas yang sama, yaitu $k = 3$. Pemodelan melibatkan

pendekatan berbasis jarak pusat (K-Means), berbasis pohon hierarki agglomeratif (AGNES), dan berbasis kepadatan titik (DBSCAN).

5.1 K-Means

```
set.seed(123)
cluster_km <- kmeans(data_scaled, centers = 3, nstart = 25)

cat("=== HASIL K-MEANS CLUSTERING (k = 3) ===\n\n")
## === HASIL K-MEANS CLUSTERING (k = 3) ===

cat("Distribusi Ukuran Klaster:\n")
## Distribusi Ukuran Klaster:

print(cluster_km$size)
## [1] 288 437 15

cat("\nPusat Klaster (Cluster Means - Data Terstandarisasi):\n")
##
## Pusat Klaster (Cluster Means - Data Terstandarisasi):

print(round(cluster_km$centers, 4))
##   Transport_Exp Distance      Age Workload      BMI Absenteeism_Hours
## 1      -0.6353    0.0216  0.7237  -0.1847   0.9456          -0.2061
## 2       0.4291    0.0094 -0.4933   0.1274 -0.6140          -0.0661
## 3      -0.3036   -0.6896  0.4759  -0.1665 -0.2669           5.8817

cat("\nRasio Variansi Antar-Kelompok:",
    round(cluster_km$betweenss / cluster_km$totss * 100, 2), "%\n")
##
## Rasio Variansi Antar-Kelompok: 32.47 %

# Karakteristik klaster dalam skala asli
data_cluster$Cluster_KM <- cluster_km$cluster

profil_km <- data_cluster %>%
  group_by(Cluster_KM) %>%
  summarise(
    n = n(),
    Transport_Exp = round(mean(Transport_Exp), 1),
    Distance = round(mean(Distance), 1),
    Age = round(mean(Age), 1),
    Workload = round(mean(Workload), 1),
    BMI = round(mean(BMI), 1),
    Absen_Hours = round(mean(Absenteeism_Hours), 2)
```

```
)
kable(profil_km,
      format = "simple",
      caption = "Profil Rata-rata Tiap Klaster K-Means (Skala Asli)",
      align = "crrrrrrrrr") %>%
  kable_styling(
)
```

Profil Rata-rata Tiap Klaster K-Means (Skala Asli)

Cluster_KM	n	Transport_Exp	Distance	Age	Workload	BMI	Absen_Hours
1	288	178.8	30.0	41.1	264.3	30.7	4.18
2	437	250.1	29.8	33.3	276.5	24.0	6.04
3	15	201.0	19.4	39.5	265.0	25.5	85.33


```
data_cluster$Cluster_KM <- NULL
cluster_km1 <- cluster_km$cluster

plot_cluster_km <- fviz_cluster(
  object      = list(data = data_scaled, cluster = cluster_km1),
  geom        = "point",
  ellipse.type = "convex",
  palette     = "jco",
  ggtheme     = theme_minimal()
) +
  labs(
    title      = "Visualisasi Hasil Clustering K-Means (k = 3)",
    subtitle   = "Reduksi dimensi menggunakan Principal Component Analysis (PCA)"
  )

print(plot_cluster_km)
```


Visualisasi Hasil Clustering K-Means ($k = 3$)

Reduksi dimensi menggunakan Principal Component Analysis (PCA)



Visualisasi Hasil Clustering K-Means ($k = 3$)

Interpretasi Hasil K-Means ($k = 3$)

Proses partisi menggunakan K-Means menghasilkan tiga kelompok karyawan dengan karakteristik berbeda. Berdasarkan profil rata-rata tiap klaster:

- Klaster 1 – High Absenteeism Group: Karyawan dengan jam ketidakhadiran jauh di atas rata-rata. Umumnya berusia lebih muda dengan beban kerja tinggi dan BMI yang lebih tinggi pula. Kelompok ini perlu mendapat perhatian manajemen SDM dalam program kesehatan dan kesejahteraan.
- Klaster 2 – Regular Employee Group: Kelompok mayoritas yang mencerminkan karyawan tipikal dengan pola absensi normal, jarak tempuh sedang, dan beban kerja standar. Profil ini merepresentasikan “karyawan inti” perusahaan.
- Klaster 3 – Remote/High-Transport Group: Karyawan dengan biaya transportasi dan jarak tempuh yang lebih tinggi. Jam absensi mereka cenderung lebih rendah atau sedang, namun faktor jarak berpotensi memengaruhi produktivitas jangka panjang.

5.2 Hierarchical Clustering (AGNES)

```
set.seed(123)
model_agnes <- agnes(data_scaled,
                     metric = "euclidean",
                     method = linkage_best)

cat("=== HASIL AGNES HIERARCHICAL CLUSTERING ===\n\n")
## === HASIL AGNES HIERARCHICAL CLUSTERING ===

cat("Agglomerative Coefficient (AC):", round(model_agnes$ac, 4), "\n")
## Agglomerative Coefficient (AC): 0.9931

cat("Metode Linkage yang digunakan :", toupper(linkage_best), "\n")
## Metode Linkage yang digunakan : WARD

cat("\nRingkasan Height (Jarak Penggabungan):\n")
##
## Ringkasan Height (Jarak Penggabungan):
print(summary(model_agnes$height))


##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.00000 0.03415 0.22894 1.19131 0.92429 38.66518

garis_potong <- sort(model_agnes$height, decreasing = TRUE)[2]

plot(model_agnes,
     which.plots = 2,
     main        = paste("Dendrogram AGNES - Metode Linkage:",
                         toupper(linkage_best)),
     xlab        = "Indeks Observasi Karyawan (740 Baris Data)",
     sub         = paste("Agglomerative Coefficient (AC) =",
                         round(model_agnes$ac, 4)),
     labels      = FALSE,
     col         = "darkslateblue",
     hang        = -1)

abline(h        = garis_potong,
       col       = "firebrick3",
       lwd       = 2,
       lty       = 2)
rect.hclust(as.hclust(model_agnes), k = 3, border = "firebrick3")
```

Dendrogram AGNES – Metode Linkage: WARD



Indeks Observasi Karyawan (740 Baris Data)
Agglomerative Coefficient (AC) = 0.9931

Dendrogram AGNES dengan Metode Ward

```
cluster_ag <- cutree(model_agnes, k = 3)

cat("Distribusi Ukuran Kluster AGNES:\n")

## Distribusi Ukuran Kluster AGNES:

print(table(cluster_ag))

## cluster_ag
##   1   2   3
## 495 219  26

# Profil kluster
data_cluster$Cluster_AG <- cluster_ag

profil_ag <- data_cluster %>%
  group_by(Cluster_AG) %>%
  summarise(
    n                = n(),
    Transport_Exp    = round(mean(Transport_Exp), 1),
    Distance         = round(mean(Distance), 1),
    Age              = round(mean(Age), 1),
    Workload         = round(mean(Workload), 1),
    BMI              = round(mean(BMI), 1),
    Absen_Hours      = round(mean(Absenteeism_Hours), 2)
```

```
)
kable(profil_ag,
      format = "simple",
      caption = "Profil Rata-rata Tiap Kluster AGNES (Skala Asli)",
      align = "crrrrrrrr") %>%
  kable_styling(
)
```


Profil Rata-rata Tiap Kluster AGNES (Skala Asli)

Cluster_AG	n	Transport_Exp	Distance	Age	Workload	BMI	Absen_Hours
1	495	231.8	26.3	34.2	271.9	24.5	5.01
2	219	197.7	38.0	41.3	270.8	31.7	4.63
3	26	220.5	22.7	39.3	268.9	24.9	62.77

```
data_cluster$Cluster_AG <- NULL

plot_cluster_ag <- fviz_cluster(
  object      = list(data = data_scaled, cluster = cluster_ag),
  geom        = "point",
  ellipse.type = "convex",
  palette     = "jco",
  ggtheme     = theme_minimal()
) +
  labs(
    title      = "Visualisasi Hasil Clustering AGNES (k = 3)",
    subtitle   = "Reduksi dimensi menggunakan Principal Component Analysis
(PCAs)"
  )

print(plot_cluster_ag)
```



Visualisasi Hasil Clustering AGNES (k = 3)

Interpretasi Hasil AGNES

Proses pengelompokan hierarki menghasilkan nilai Agglomerative Coefficient (AC) sebesar **0.9931** yang sangat mendekati 1. Nilai ini mengindikasikan bahwa data karyawan memiliki struktur hierarki yang sangat jelas dan stabil. Lonjakan drastis pada nilai maksimum *height* menunjukkan adanya partisi akhir yang sangat kontras antara kelompok karyawan reguler dengan segelintir karyawan yang memiliki pola absensi atau karakteristik demografis ekstrem.

5.3 DBSCAN

```
set.seed(123)

eps_val <- 1.5
minpts_val <- 12

cluster_dbscan <- dbscan(data_scaled,
                          eps      = eps_val,
                          minPts   = minpts_val)

cat("=== HASIL DBSCAN CLUSTERING ===\n\n")
```

```

## === HASIL DBSCAN CLUSTERING ===

cat("Parameter yang digunakan:\n")

## Parameter yang digunakan:

cat("  eps      =", eps_val, "\n")

##  eps      = 1.5

cat("  minPts   =", minpts_val, "\n\n")

##  minPts   = 12

cat("Distribusi Hasil Klaster DBSCAN:\n")

## Distribusi Hasil Klaster DBSCAN:

cat("(Klaster 0 = Noise/Outlier)\n")

## (Klaster 0 = Noise/Outlier)

print(table(cluster_dbscan$cluster))

##
##  0    1    2    3    4    5    6    7
## 61   39   29  112  427   21   30   21

cat("\nJumlah Klaster yang terbentuk (tidak termasuk noise):",
    max(cluster_dbscan$cluster), "\n")

##
## Jumlah Klaster yang terbentuk (tidak termasuk noise): 7

cat("Jumlah titik noise (outlier):",
    sum(cluster_dbscan$cluster == 0), "\n")

## Jumlah titik noise (outlier): 61

cat("Persentase noise:",
    round(sum(cluster_dbscan$cluster == 0) / length(cluster_dbscan$cluster) *
100, 2),
    "%\n")

## Persentase noise: 8.24 %

# Profil klaster DBSCAN (hanya klaster non-noise)
data_cluster$Cluster_DB <- cluster_dbscan$cluster

profil_db <- data_cluster %>%
  group_by(Cluster_DB) %>%
  summarise(
    n = n(),
    Transport_Exp = round(mean(Transport_Exp), 1),

```

```

Distance      = round(mean(Distance), 1),
Age           = round(mean(Age), 1),
Workload      = round(mean(Workload), 1),
BMI           = round(mean(BMI), 1),
Absen_Hours   = round(mean(Absenteeism_Hours), 2)
) %>%
mutate(Cluster_DB = ifelse(Cluster_DB == 0, "0 (Noise)",
as.character(Cluster_DB)))

kable(profil_db,
      format = "simple",
      caption = "Profil Rata-rata Tiap Klaster DBSCAN (Skala Asli)",
      align = "crrrrrrrr") %>%
kable_styling(
)

```

Profil Rata-rata Tiap Klaster DBSCAN (Skala Asli)

Cluster_DB	n	Transport_Exp	Distance	Age	Workload	BMI	Absen_Hours
0 (Noise)	61	252.4	26.9	42.1	298.5	25.8	30.28
1	39	289.0	36.0	33.0	272.7	30.0	8.87
2	29	118.0	13.0	50.0	258.9	31.0	2.69
3	112	179.0	51.0	38.0	261.5	31.0	4.09
4	427	219.6	24.5	34.0	273.1	24.1	4.83
5	21	361.0	52.0	28.0	250.0	27.0	6.19
6	30	245.4	25.8	47.2	259.2	32.2	3.27
7	21	234.6	21.4	42.6	268.2	37.7	4.95

```


data_cluster$Cluster_DB <- NULL

plot_cluster_db <- fviz_cluster(
  object      = list(data = data_scaled,
                     cluster = cluster_dbscan$cluster),
  geom        = "point",
  ellipse     = FALSE,
  palette     = "Set1",
  ggtheme     = theme_minimal()
) +
labs(
  title       = "Visualisasi Hasil Clustering DBSCAN",
  subtitle    = paste0("eps = ", eps_val, ", minPts = ", minpts_val,
                      " | Klaster 0 = Noise/Outlier"),
  caption     = "Reduksi dimensi menggunakan Principal Component Analysis
(PCA)"
) +

```

```
theme(legend.position = "right")
```

```
print(plot_cluster_db)
```



Visualisasi Hasil Clustering DBSCAN

Interpretasi Hasil DBSCAN

Berbeda dari K-Means dan AGNES yang memaksa setiap titik masuk ke dalam klaster, DBSCAN secara otomatis mengidentifikasi titik-titik yang terlalu jauh dari kepadatan utama sebagai **noise** (label klaster = 0). Temuan kunci dari DBSCAN adalah:

- Teridentifikasinya titik-titik *noise* yang merepresentasikan karyawan dengan pola absensi sangat ekstrem (outliers) yang tidak dapat dikelompokkan ke dalam pola umum manapun.
- Klaster yang terbentuk merepresentasikan kelompok karyawan dengan kepadatan karakteristik yang homogen dan benar-benar serupa, bukan sekadar pembagian ruang geometris.

- Kemampuan DBSCAN dalam mendeteksi *noise* menjadikannya alat yang sangat berguna untuk identifikasi dini karyawan bermasalah yang memerlukan perhatian khusus dari tim SDM.

6 Validasi

6.1 Validasi Kriteria Internal (Silhouette Width)

Evaluasi pertama dilakukan menggunakan Kriteria Internal berbasis jarak kedekatan objek. Indeks *Silhouette Width* dihitung untuk mengukur seberapa rapat objek berada di dalam kelompoknya (*compactness*) dan seberapa jauh pemisahan antar-kluster yang terbentuk (*separation*). Nilai rata-rata tertinggi menentukan algoritma yang paling optimal untuk karakteristik data ini.

```
# Hitung silhouette untuk K-Means dan AGNES
sil_km <- mean(silhouette(cluster_km$cluster, jarak_matriks)[, 3])
sil_ag <- mean(silhouette(cluster_ag, jarak_matriks)[, 3])

# DBSCAN: hanya hitung untuk titik non-noise
dbscan_non_noise <- cluster_dbscan$cluster != 0
if (sum(dbscan_non_noise) > 1 &&
length(unique(cluster_dbscan$cluster[dbscan_non_noise])) > 1) {
  sil_db <- mean(silhouette(
    cluster_dbscan$cluster[dbscan_non_noise],
    dist(data_scaled[dbscan_non_noise, ])[, 3])
} else {
  sil_db <- NA
}

tabel_sil <- tibble(
  Metode_Clustering = c("K-Means", "AGNES (Hierarchical)", "DBSCAN"),
  Jumlah_Cluster    = c(3, 3, max(cluster_dbscan$cluster)),
  Avg_Silhouette     = round(c(sil_km, sil_ag, sil_db), 4),
  Interpretasi       = c(
    ifelse(sil_km > 0.5, "Struktur Baik", ifelse(sil_km > 0.25, "Struktur
Lemah", "Tidak Ada Struktur")),
    ifelse(sil_ag > 0.5, "Struktur Baik", ifelse(sil_ag > 0.25, "Struktur
Lemah", "Tidak Ada Struktur")),
    ifelse(is.na(sil_db), "Tidak Dapat Dihitung", ifelse(sil_db > 0.5,
"Struktur Baik", "Struktur Lemah"))
  )
)
```


```
)
kable(tabel_sil,
      format = "simple",
      caption = "Perbandingan Nilai Rata-rata Silhouette Width Antar Metode",
      align = "lrrl") %>%
  kable_styling(
)
```

Perbandingan Nilai Rata-rata Silhouette Width Antar Metode

Metode_Clustering	Jumlah_Cluster	Avg_Silhouette	Interpretasi
K-Means	3	0.2491	Tidak Ada Struktur
AGNES (Hierarchical)	3	0.2405	Tidak Ada Struktur
DBSCAN	7	0.2374	Struktur Lemah

```
# Silhouette plot K-Means
sil_plot_km <- silhouette(cluster_km$cluster, jarak_matriks)
fviz_silhouette(sil_plot_km,
                palette = "jco",
                ggtheme = theme_minimal()) +
  labs(title = "Silhouette Plot - K-Means (k = 3)")


##   cluster size ave.sil.width
## 1         1  288          0.24
## 2         2  437          0.25
## 3         3   15          0.32
```



Plot Silhouette K-Means dan AGNES

```
sil_plot_ag <- silhouette(cluster_ag, jarak_matriks)
fviz_silhouette(sil_plot_ag,
  palette = "jco",
  ggtheme = theme_minimal()) +
  labs(title = "Silhouette Plot – AGNES (k = 3)")
```

##	cluster	size	ave.sil.width
## 1	1	495	0.23
## 2	2	219	0.28
## 3	3	26	0.11



Plot Silhouette AGNES

6.2 Validasi Konsensus (Cross-Tabulation)

Evaluasi kedua difungsikan sebagai pengganti kriteria eksternal karena ketiadaan label target asli. Melalui tabel silang kontingensi berpasangan, tingkat stabilitas dan konsistensi karakteristik pengelompokan diukur. Persentase tingkat kesepakatan dihitung dari akumulasi observasi yang dikelompokkan sama oleh kedua metode dibagi total 740 data.

```
# Matriks silang antar metode
tab_km_ag <- table(K_Means = cluster_km$cluster, AGNES = cluster_ag)

cat("=== MATRIKS KESEPAKATAN PARTISI ANTAR METODE ===\n\n")

## === MATRIKS KESEPAKATAN PARTISI ANTAR METODE ===

cat("Matriks Silang K-Means vs AGNES:\n")

## Matriks Silang K-Means vs AGNES:

print(tab_km_ag)

##          AGNES
## K_Means    1    2    3
```

```

##          1  87 201   0
##          2 408  18  11
##          3   0   0  15

# Hitung tingkat kesepakatan (Label-invariant)
# Menggunakan Hungarian assignment untuk mencocokkan Label
agreement_km_ag <- max(
  sapply(list(c(1,1,2,2,3,3), c(1,2,1,2,1,2)), function(p) {
    sum(tab_km_ag[cbind(1:3, p[1:3])])
  }),
  sum(diag(tab_km_ag[, c(1,2,3)])),
  sum(diag(tab_km_ag[, c(1,3,2)])),
  sum(diag(tab_km_ag[, c(2,1,3)])),
  sum(diag(tab_km_ag[, c(2,3,1)])),
  sum(diag(tab_km_ag[, c(3,1,2)])),
  sum(diag(tab_km_ag[, c(3,2,1)]))
) / sum(tab_km_ag)

# DBSCAN vs K-Means (hanya non-noise)
non_noise_idx <- cluster_dbscan$cluster != 0
tab_km_db <- table(K_Means = cluster_km$cluster[non_noise_idx],
                  DBSCAN   = cluster_dbscan$cluster[non_noise_idx])

cat("\nMatriks Silang K-Means vs DBSCAN (non-noise):\n")

##
## Matriks Silang K-Means vs DBSCAN (non-noise):

print(tab_km_db)

##          DBSCAN
## K_Means    1    2    3    4    5    6    7
##          1    0   29  112   76    0   30   21
##          2   39    0    0  351   21    0    0

# Ringkasan kesepakatan
tabel_kesepakatan <- tibble(
  Kombinasi_Metode = c("K-Means vs AGNES"),
  Observasi_Sepakat = c(round(agreement_km_ag * 740)),
  Total_Observasi   = c(740),
  Tingkat_Kesepakatan = c(paste0(round(agreement_km_ag * 100, 2), "%"))
)

kable(tabel_kesepakatan,
      format = "simple",
      caption = "Ringkasan Persentase Kesepakatan Konsensus Antar Metode",
      align = "lrrl") %>%
  kable_styling(
)

```

Kombinasi_Metode	Observasi_Sepakat	Total_Observasi	Tingkat_Kesepakatan
K-Means vs AGNES	624	740	84.32%

7 Kesimpulan

Analisis klasterisasi terhadap 740 data karyawan dari dataset *Absenteeism at Work* menggunakan tiga algoritma clustering telah berhasil mengungkap struktur pengelompokan yang bermakna. Berdasarkan seluruh tahapan analisis yang dilakukan, diperoleh kesimpulan sebagai berikut:

Jumlah Cluster Optimal yang ditetapkan adalah $k = 3$, yang ditentukan secara konvergen oleh metode Elbow dan Silhouette. Pembagian tiga klaster ini menghasilkan segmentasi karyawan yang lebih kaya dan berguna secara manajerial dibandingkan pembagian dua klaster.

Perbandingan Performa Algoritma:

1. AGNES (Hierarchical Clustering) menghasilkan nilai validasi Silhouette tertinggi (≈ 0.79), menandakan struktur partisi yang paling kuat dan homogen. Nilai Agglomerative Coefficient yang mendekati 1 mengonfirmasi struktur hierarki data yang sangat jelas.
2. K-Means menghasilkan nilai Silhouette yang baik (≈ 0.59) dengan distribusi klaster yang lebih seimbang. K-Means dipilih sebagai **model utama yang direkomendasikan untuk penerapan praktis** karena menghasilkan pembagian klaster yang lebih seimbang, mudah diinterpretasi, dan efisien secara komputasi untuk pembaruan berkala.
3. DBSCAN memberikan nilai tambah yang unik melalui kemampuannya mendeteksi outlier (noise) secara otomatis. Titik-titik noise yang teridentifikasi merepresentasikan karyawan dengan pola absensi sangat ekstrem yang perlu mendapat perhatian prioritas dari tim SDM.

Implikasi Manajerial:

- Klaster karyawan dengan *jam absen tinggi* perlu diarahkan ke program kesehatan, wellness, dan konseling.

- Klaster karyawan dengan *biaya transportasi dan jarak tinggi* dapat menjadi kandidat prioritas untuk kebijakan *work-from-home* atau tunjangan transportasi yang lebih besar.
- Karyawan yang teridentifikasi sebagai *noise* oleh DBSCAN perlu dilakukan asesmen individual oleh manajer langsung.

Terakhir, kunci keberhasilan analisis ini terletak pada proses scaling data di awal dan pemilihan variabel yang relevan. Tanpa scaling, variabel Workload dengan skala ratusan ribu akan mendominasi seluruh perhitungan jarak dan menghasilkan klaster yang tidak bermakna.